ГРНТИ 28.23.15, 28.23.37
ASJC 1707, 1702
OECD 1.02

Исследование методов доменной адаптации нейронных сетей для семантической сегментации при переносе с синтетических изображений на реальные

Н. М. Коршунов
кафедра инженерной кибернетики НИТУ «МИСиС»
Москва, Россия
m2303488@edu.misis.ru

Аннотация — Рассматривается перенос моделей семантической сегментации с размеченных синтетических изображений на реальные изображения без доступной обучающей разметки целевого домена. Цель работы — систематизировать математические механизмы доменной адаптации и определить условия их корректного сравнения. Сопоставляются статистическое и транспортное согласование, состязательное обучение, минимизация энтропии, самообучение, согласованность предсказаний и контрастивные критерии. На примере опубликованных исследований показано, почему улучшение всей адаптационной схемы следует отличать от эффекта отдельного компонента. Сформулирована постановка переноса GTA5 → Cityscapes и предложен протокол будущего сравнения по mIoU, качеству отдельных классов и вычислительным затратам. Работа представляет обзор и проект исследования; собственные экспериментальные результаты на данном этапе не приводятся.

Ключевые слова — Доменная адаптация; перенос с синтетических данных на реальные (Synthetic-to-Real); семантическая сегментация; сдвиг домена (domain shift); обучение без разметки целевого домена (UDA); псевдоразметка (pseudo-labeling)

I. ВВЕДЕНИЕ

Семантическая сегментация сопоставляет каждому пикселю изображения класс объекта: дорога, автомобиль, пешеход и другие категории. Пиксельная разметка реальных сцен требует значительных трудозатрат. Синтетические сцены позволяют получать изображения и соответствующие метки из виртуальной среды, однако различия текстур, освещения, геометрии и частот классов затрудняют перенос модели на фотографии.

Доменная адаптация без целевой разметки (unsupervised domain adaptation, UDA) использует размеченные изображения исходного домена и неразмеченные изображения целевого домена. Важен не только выбор сегментационной сети, но и критерий, позволяющий извлечь обучающий сигнал из целевых данных. В AdaptSegNet используется состязательное согласование карт предсказаний [1]; DACS сочетает псевдоразметку с междоменным смешиванием изображений [2]; DAFormer показывает существенное влияние архитектуры и стратегии обучения [3].

Итоговые метрики этих работ не позволяют ранжировать отдельные математические принципы: одновременно меняются модель, начальные веса, аугментации и правила обучения. Цель работы — сопоставить механизмы адаптации и сформулировать условия их проверки. Аналитический результат включает систематизацию критериев, их ограничений и правил сравнения опубликованных оценок.

II. АНАЛИЗ РАБОТ

A. Смежные исследования и исходная проблема

С. Аскари Хеммат использует Unreal Engine для подготовки синтетических сцен с мебелью [4]. Работа близка способом получения данных, но её показатели детекции не характеризуют сегментацию. Л. Б. Комендала рассматривает сегментацию дорожных сцен CamVid [5], без переноса GTA5 → Cityscapes. И. И. Курочкин и соавторы применяют нейросети к классификации микроскопических изображений криогелей [6]. Эти работы задают смежный контекст; их метрики не используются для количественной оценки UDA.

B. Основные направления адаптации

Статистические критерии сравнивают распределения признаков через ядерные средние или ковариации [7, 8]. Оптимальный транспорт строит соответствия между наблюдениями, минимизируя стоимость переноса массы [9]. Состязательные методы обучают модель

скрывать различие доменов от дополнительного классификатора. В AdaptSegNet согласование проводится на уровне пространственно организованных предсказаний сегментатора [1].

Другая группа подходов использует структуру ответов на целевых изображениях. Энтропийный критерий поощряет определённые предсказания [10]. Самообучение превращает часть предсказаний в обучающие метки. Согласованность требует устойчивости ответов к допустимым преобразованиям; в MIC ученик предсказывает классы по частично закрытому изображению, используя псевдометки учителя [11]. Контрастивные методы, например SePiCo, добавляют семантические ограничения на расположение признаков [12].

Направления пересекаются. В DACS псевдометки используются вместе со смешиванием исходных и целевых изображений и схемой «учитель — ученик». DAFormer дополняет самообучение выборкой редких классов, регуляризацией признаков и разогревом скорости обучения. Поэтому название алгоритма обозначает целую реализацию, а не единственный математический критерий. В работе рассматриваются шесть перечисленных направлений; преобразование внешнего вида изображений не выделяется в самостоятельный предмет сравнения.

C. Что показывают опубликованные оценки

Для оценки всей схемы нужна модель, обученная только на исходном домене (source only). В AdaptSegNet многоуровневое согласование повышает mIoU с 36,6 до 42,4, то есть на 5,8 процентного пункта (п. п.) [1, табл. 1]. В DACS соответствующая пара равна 32,85 и 52,14, прирост составляет 19,29 п. п. [2, табл. 1]. Обе оценки относятся к GTA5 → Cityscapes и 19 классам, но условия обучения различаются. Разница приростов не доказывает преимущество самообучения над состязательным критерием в одинаковой модели.

Внутреннее сравнение DACS (табл. I) показывает риск ухудшения при псевдоразметке. Naive Mixing смешивает целевые изображения между собой, DACS — исходные и целевые. Различие результатов характеризует эти реализации, а не направление самообучения в целом.

Таблица I. Опубликованное сравнение вариантов DACS на GTA5 → Cityscapes [2, табл. 3]

Вариант	mIoU, %	Δ, п. п.
Только исходный домен	32,85	—
Псевдоразметка без смешивания	22,97	−9,88
Naive Mixing	35,08	+2,23
DACS	52,14	+19,29

Δ рассчитана относительно 32,85. Это результаты авторов DACS, не собственные эксперименты.

Эффект отдельного компонента оценивают относительно уже адаптирующейся системы. Добавление MIC к DAFormer изменяет mIoU с 68,3 до 70,6, то есть на 2,3 п. п. [11, табл. 7]. Это дополнительный эффект MIC; исходные 68,3 mIoU [3] характеризуют сочетание архитектуры и правил обучения. Сопоставимого численного примера для CORAL в выбранном сценарии не приводится.

III. ПОСТАНОВКА ЗАДАЧИ

Пусть $\mathcal{D}_s = \{(x_i^s, y_i^s)\}_{i=1}^{N_s}$ — размеченная исходная выборка, а $\mathcal{D}_t = \{x_j^t\}_{j=1}^{N_t}$ — целевая выборка без доступных обучающих меток. Пространство из C классов считается общим. Сеть с параметрами θ выдаёт в пикселе u вектор вероятностей $p_\theta(x)_u$; итоговая метка выбирается по максимальной вероятности. Распределения изображений двух доменов различаются.

Схема разделения обучающих и проверочных данных приведена на рис. 1.

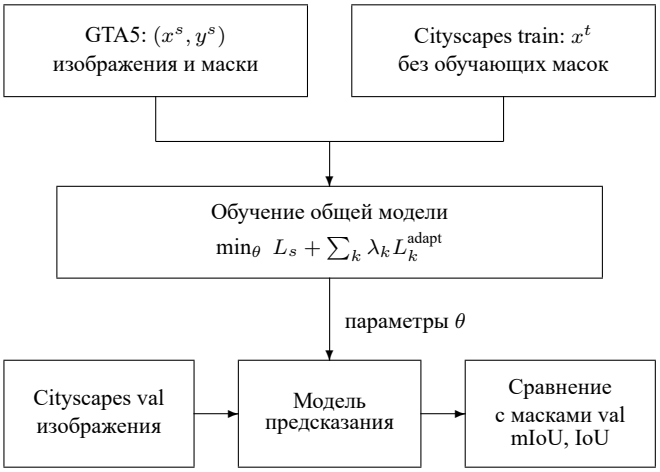


Рис. 1. Постановка GTA5 → Cityscapes: обучение без целевых меток и оценка на отдельной проверочной выборке.

На исходных данных минимизируется перекрёстная энтропия:

$$L_s(\theta) = -\frac{1}{N_s}\sum_{i=1}^{N_s}\frac{1}{|\Omega_i|}\sum_{u\in\Omega_i}\log p_{\theta,y_{iu}^s}(x_i^s)_u, \qquad (1)$$

где Ω_i — множество учитываемых пикселей. Для целевых обучающих изображений такая потеря недоступна. Общая схема вводит дополнительный критерий:

$$\min_\theta\ L_s(\theta) + \sum_k \lambda_k L_k^{\text{adapt}}(\theta), \qquad \lambda_k \geq 0. \qquad (2)$$

Формула задаёт способ объединения критериев, но не требует одновременного использования всех направлений. Для состязательной схемы добавляется максимизация по параметрам дискриминатора, для транспорта — внутренняя задача определения соответствий.

Основной сценарий — GTA5 [13] как источник синтетических изображений и Cityscapes [14] как целевой домен. Целевые обучающие маски не используются при оптимизации. Маски отдельной проверочной выборки нужны для оценки. Если они применяются для выбора гиперпараметров или момента остановки, это должно явно отражаться в протоколе: такой режим отличается от выбора модели без целевой разметки. SYNTHIA может

рассматриваться позднее как дополнительный источник; результаты для 13, 16 и 19 классов нельзя смешивать в одной оценке.

Качество оценивается средней по классам мерой пересечения с объединением:

$$\mathrm{mIoU} = \frac{100}{C} \sum_{c=1}^{C} \frac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FP}_c + \mathrm{FN}_c}. \tag{3}$$

Числа истинно положительных, ложноположительных и ложноотрицательных пикселей накапливаются по всей проверочной выборке. Дополнительно рассматриваются IoU каждого класса, время обучения и пиковая память ускорителя. Средняя метрика может скрывать ухудшение редких категорий, поэтому одного mIoU недостаточно.

IV. ОПИСАНИЕ МЕТОДОВ

A. Статистическое и транспортное согласование

Пусть z — вектор признаков, извлечённый из пространственной позиции карты сети, а P_s и P_t — распределения исходных и целевых признаков. Ядерный критерий MMD сравнивает их средние вложения в пространство $\mathcal{H}$ [7]:

$$L_{\mathrm{MMD}} = \left\| \mathbb{E}_{P_s} \phi(z) - \mathbb{E}_{P_t} \phi(z) \right\|_{\mathcal{H}}^2. \tag{4}$$

На практике используются значения ядра $k(z, z') = \langle \phi(z), \phi(z') \rangle$. Сеть обновляется по исходной ошибке и оценке MMD, вычисленной на выбранных признаках двух доменов. Выбор ядра, его масштаба и способа выборки пикселей влияет на результат. Полная попарная оценка требует квадратичного числа операций по числу выбранных признаков.

Deep CORAL согласует ковариации C_s и C_t признаков размерности d [8]:

$$L_{\mathrm{CORAL}} = \frac{1}{4d^2} \| C_s - C_t \|_F^2. \tag{5}$$

Ковариации вычисляются после центрирования признаков. Их совпадение не гарантирует совпадения средних или полных распределений. В сегментационной модели оба критерия можно применять к выборке пространственных признаков; согласование без учёта классов способно сблизить семантически разные объекты.

Оптимальный транспорт задаёт матрицу неотрицательных переносимых масс γ. Для исходных весов a и целевых весов b, каждый из которых суммируется в единицу, рассматривается задача

$$\min_{\gamma \in \Pi(a,b)} \langle \gamma, M \rangle + \varepsilon \sum_{i,j} \gamma_{ij} (\log \gamma_{ij} - 1), \tag{6}$$

где $\Pi(a,b) = \{\gamma \geq 0 : \gamma \mathbf{1} = a, \gamma^T \mathbf{1} = b\}$, M — стоимость сопоставления, $\varepsilon > 0$. Принимается $0 \log 0 = 0$. Алгоритм Синкхорна попеременно нормирует строки и столбцы ядра $K_{ij} = \exp(-M_{ij}/\varepsilon)$ [9]. После расчёта плана обновляются параметры сети. Семантическая информация может включаться в стоимость; память для матрицы попарных стоимостей ограничивает число используемых признаков.

B. Состязательное согласование

Дискриминатор D_φ оценивает вероятность принадлежности исходному домену по признакам либо предсказаниям $r_\theta(x)$. Базовая постановка имеет вид

$$\begin{aligned} V(\theta, \varphi) = {} & \mathbb{E}_s \log D_\varphi(r_\theta(x)) \\ & + \mathbb{E}_t \log[1 - D_\varphi(r_\theta(x))], \\ & \min_\theta \max_\varphi \; L_s(\theta) + \lambda V(\theta, \varphi). \end{aligned} \tag{7}$$

Максимизация обучает различать домены, минимизация по θ затрудняет это различение. Используются попеременные градиентные шаги; конкретные алгоритмы могут менять генераторную потерю для устойчивости. AdaptSegNet применяет этот принцип к картам классов [1]. Основные ограничения — неустойчивость минимаксного обучения и возможность подавления полезных различий. Низкая точность дискриминатора сама по себе не подтверждает правильность сегментации.

C. Минимизация энтропии

Для вероятностей классов p_c нормированная энтропия равна

$$H(p) = -\frac{1}{\log C} \sum_{c=1}^{C} p_c \log p_c. \tag{8}$$

Её среднее по целевым пикселям добавляется к L_s. Критерий стимулирует уверенные ответы, но уверенная ошибка также имеет малую энтропию. Поэтому важно контролировать вес регуляризации и распределение предсказываемых классов. В ADVENT различаются прямая минимизация энтропии MinEnt и состязательная обработка карт самоинформации AdvEnt [10]; их нельзя считать одной и той же процедурой оптимизации.

D. Самообучение с псевдоразметкой

Модель с фиксированными на текущем шаге параметрами $\bar{\theta}$ формирует метки $\hat{y}_u = \arg\max_c p_{\bar{\theta},c}(x^t)_u$. Для отбора можно использовать маску $w_u = \mathbf{1}[\max_c p_{\bar{\theta},c}(x^t)_u \geq \tau_{\hat{y}_u}]$ и потерю

$$L_{\mathrm{pl}} = -\frac{\sum_u w_u \log p_{\theta, \hat{y}_u}(x^t)_u}{\max(1, \sum_u w_u)}. \tag{9}$$

Псевдометки и маска фиксируются при обновлении ученика. Затем предсказания уточняются, и обучение повторяется. Пороги могут зависеть от класса, поскольку единый высокий порог часто отбирает преимущественно простые и частые категории. Это обобщённая схема отбора, а не точное воспроизведение DACS или DAFormer.

В DACS части исходных изображений вместе с истинными метками смешиваются с целевыми областями и псевдометками [2]. DAFormer использует выборку исходных изображений с редкими классами [3]. Эти механизмы помогают сохранять классовое разнообразие, но не устраняют риск закрепления ошибок автоматически. Сравнение в табл. I показывает, почему наличие псевдометок само по себе не гарантирует улучшения.

E. Согласованность предсказаний

Для двух допустимых преобразований одного изображения минимизируется расхождение ответов, например дивергенция Кульбака–Лейблера между ответом учителя q_u и ученика p_u. Геометрические преобразования требуют предварительного совмещения координат. Параметры учителя могут обновляться экспоненциальным усреднением:

$$\bar{\theta}_k = \alpha\bar{\theta}_{k-1} + (1-\alpha)\theta_k, \qquad 0 \le \alpha < 1. \qquad (10)$$

Градиент через целевой ответ учителя не проводится. В MIC применяется перекрёстная энтропия между предсказаниями ученика по маскированному изображению и псевдометками учителя по полному изображению [11]. Учитель сглаживает изменения параметров, но не получает независимой правильной разметки. Два одинаковых ответа могут быть одновременно ошибочными.

F. Контрастивные критерии

Контрастивное обучение сближает признаки одного класса и разделяет признаки разных классов. Положительные соответствия задаются исходными метками или целевыми псевдометками; отрицательные — другими классами. Вариант с прототипами сравнивает признак с представительными векторами классов через softmax от сходства, делённого на температуру. Критерии типа InfoNCE задают относительное предпочтение положительных соответствий отрицательным.

В SePiCo классы представляются прототипами, банками признаков или распределениями [12]. Для исследования важны надёжность псевдометок, обновление прототипов, температура и состав отрицательных примеров. Ошибочная метка создаёт неверное семантическое соответствие. Поэтому контрастивный член следует оценивать как дополнение к фиксированной базовой схеме, отдельно проверяя его влияние на редкие классы.

G. Проект сравнительного исследования

Будущее сравнение фиксирует разбиения данных, 19 классов, модель, начальные веса, разрешение и бюджет обучения. Каждый критерий добавляется к source only отдельно; комбинации проверяются добавлением или исключением одного компонента. Полные реализации AdaptSegNet, DACS и DAFormer служат отдельными ориентирами из литературы.

Для каждого запуска сохраняются конфигурация, случайное зерно, версия кода, правило выбора контрольной точки, mIoU, IoU классов, время обучения и пиковая память. Повторные запуски позволяют оценить среднее и стандартное отклонение; малые различия без оценки вариативности не подтверждают преимущество. Ухудшение относительно той же исходной модели означает отрицательный перенос.

Предстоит проверить прирост при единых условиях и его сохранение для редких классов. Число запусков определяется доступными ресурсами. Собственные эксперименты ещё не проводились.

СПИСОК ЛИТЕРАТУРЫ

[1] Tsai Y.-H., Hung W.-C., Schulter S. et al. Learning to Adapt Structured Output Space for Semantic Segmentation // CVPR. 2018. P. 7472–7481. Текст публикации.

[2] Tranheden W., Olsson V., Pinto J., Svensson L. DACS: Domain Adaptation via Cross-Domain Mixed Sampling // WACV. 2021. P. 1379–1389. Текст публикации.

[3] Hoyer L., Dai D., Van Gool L. DAFormer: Improving Network Architectures and Training Strategies for Domain-Adaptive Semantic Segmentation // CVPR. 2022. P. 9924–9935. Текст публикации.

[4] Аскари Хеммат С. Применение синтетических данных из UnrealEngine для обучения модели сегментации мебели // Искусственный интеллект в промышленных, коммерческих, медицинских и финансовых приложениях. Вып. 4. М.: НИТУ «МИСИС», 2025. С. 13–16. Сборник, с. 13.

[5] Комендала Л. Б. Семантическая сегментация дорожных сцен с использованием глубокого обучения // Искусственный интеллект в промышленных, коммерческих, медицинских и финансовых приложениях. Вып. 5. М.: НИТУ «МИСИС», 2026. С. 82–86. Сборник, с. 82.

[6] Kurochkin I. I., Kurochkin I. N., Kolosova O. Yu., Lozinsky V. I. Cryostructuring of Polymeric Systems: Application of Deep Neural Networks for the Classification of Structural Features Peculiar to Macroporous Poly(vinyl alcohol) Cryogels Prepared without and with the Additives of Chaotropes or Kosmotropes // Molecules. 2020. Vol. 25, no. 19. Art. 4480. DOI: 10.3390/molecules25194480.

[7] Gretton A., Borgwardt K. M., Rasch M. J. et al. A Kernel Two-Sample Test // JMLR. 2012. Vol. 13. P. 723–773. Текст публикации.

[8] Sun B., Saenko K. Deep CORAL: Correlation Alignment for Deep Domain Adaptation. 2016. arXiv:1607.01719.

[9] Cuturi M. Sinkhorn Distances: Lightspeed Computation of Optimal Transport // NeurIPS. 2013. Vol. 26. arXiv:1306.0895.

[10] Vu T.-H., Jain H., Bucher M. et al. ADVENT: Adversarial Entropy Minimization for Domain Adaptation in Semantic Segmentation // CVPR. 2019. arXiv:1811.12833.

[11] Hoyer L., Dai D., Wang H., Van Gool L. MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation // CVPR. 2023. P. 11721–11732. arXiv:2212.01322.

[12] Xie B., Li S., Li M. et al. SePiCo: Semantic-Guided Pixel Contrast for Domain Adaptive Semantic Segmentation // IEEE TPAMI. 2023. arXiv:2204.08808.

[13] Richter S. R., Vineet V., Roth S., Koltun V. Playing for Data: Ground Truth from Computer Games // ECCV. 2016. arXiv:1608.02192.

[14] Cordts M., Omran M., Ramos S. et al. The Cityscapes Dataset for Semantic Urban Scene Understanding // CVPR. 2016. P. 3213–3223. Сайт набора данных.